Advanced Problem Solving

Hashcode 2017 – Streaming Problem

Justin DITER, Arno LESAGE, Hugo VIANA

(Groupe A)

Algorithme

Ruin & Recreate(Instance, λ = 33%) :

current_instance = Copy(instance) — $O(R + C(E + V))$

Pour i de 0 à $\lambda \cdot C$: — $O(\lambda \cdot C)$

- Cache = Random cache
- Pour vidéo dans Vidéos: — $O(V)$
  - Retire la vidéo du cache

Greedy(current_instance) — $O\left(\lambda \cdot C^2\left(V \cdot R + X(V + R)\right)\right)$

Si current_instance.score > instance.score : — $O(1)$

- Swap(instance, current_instance)

Free(current_instance) — $O(\mathrm{V} + R + E \cdot \mathrm{C})$

Complexité cubique

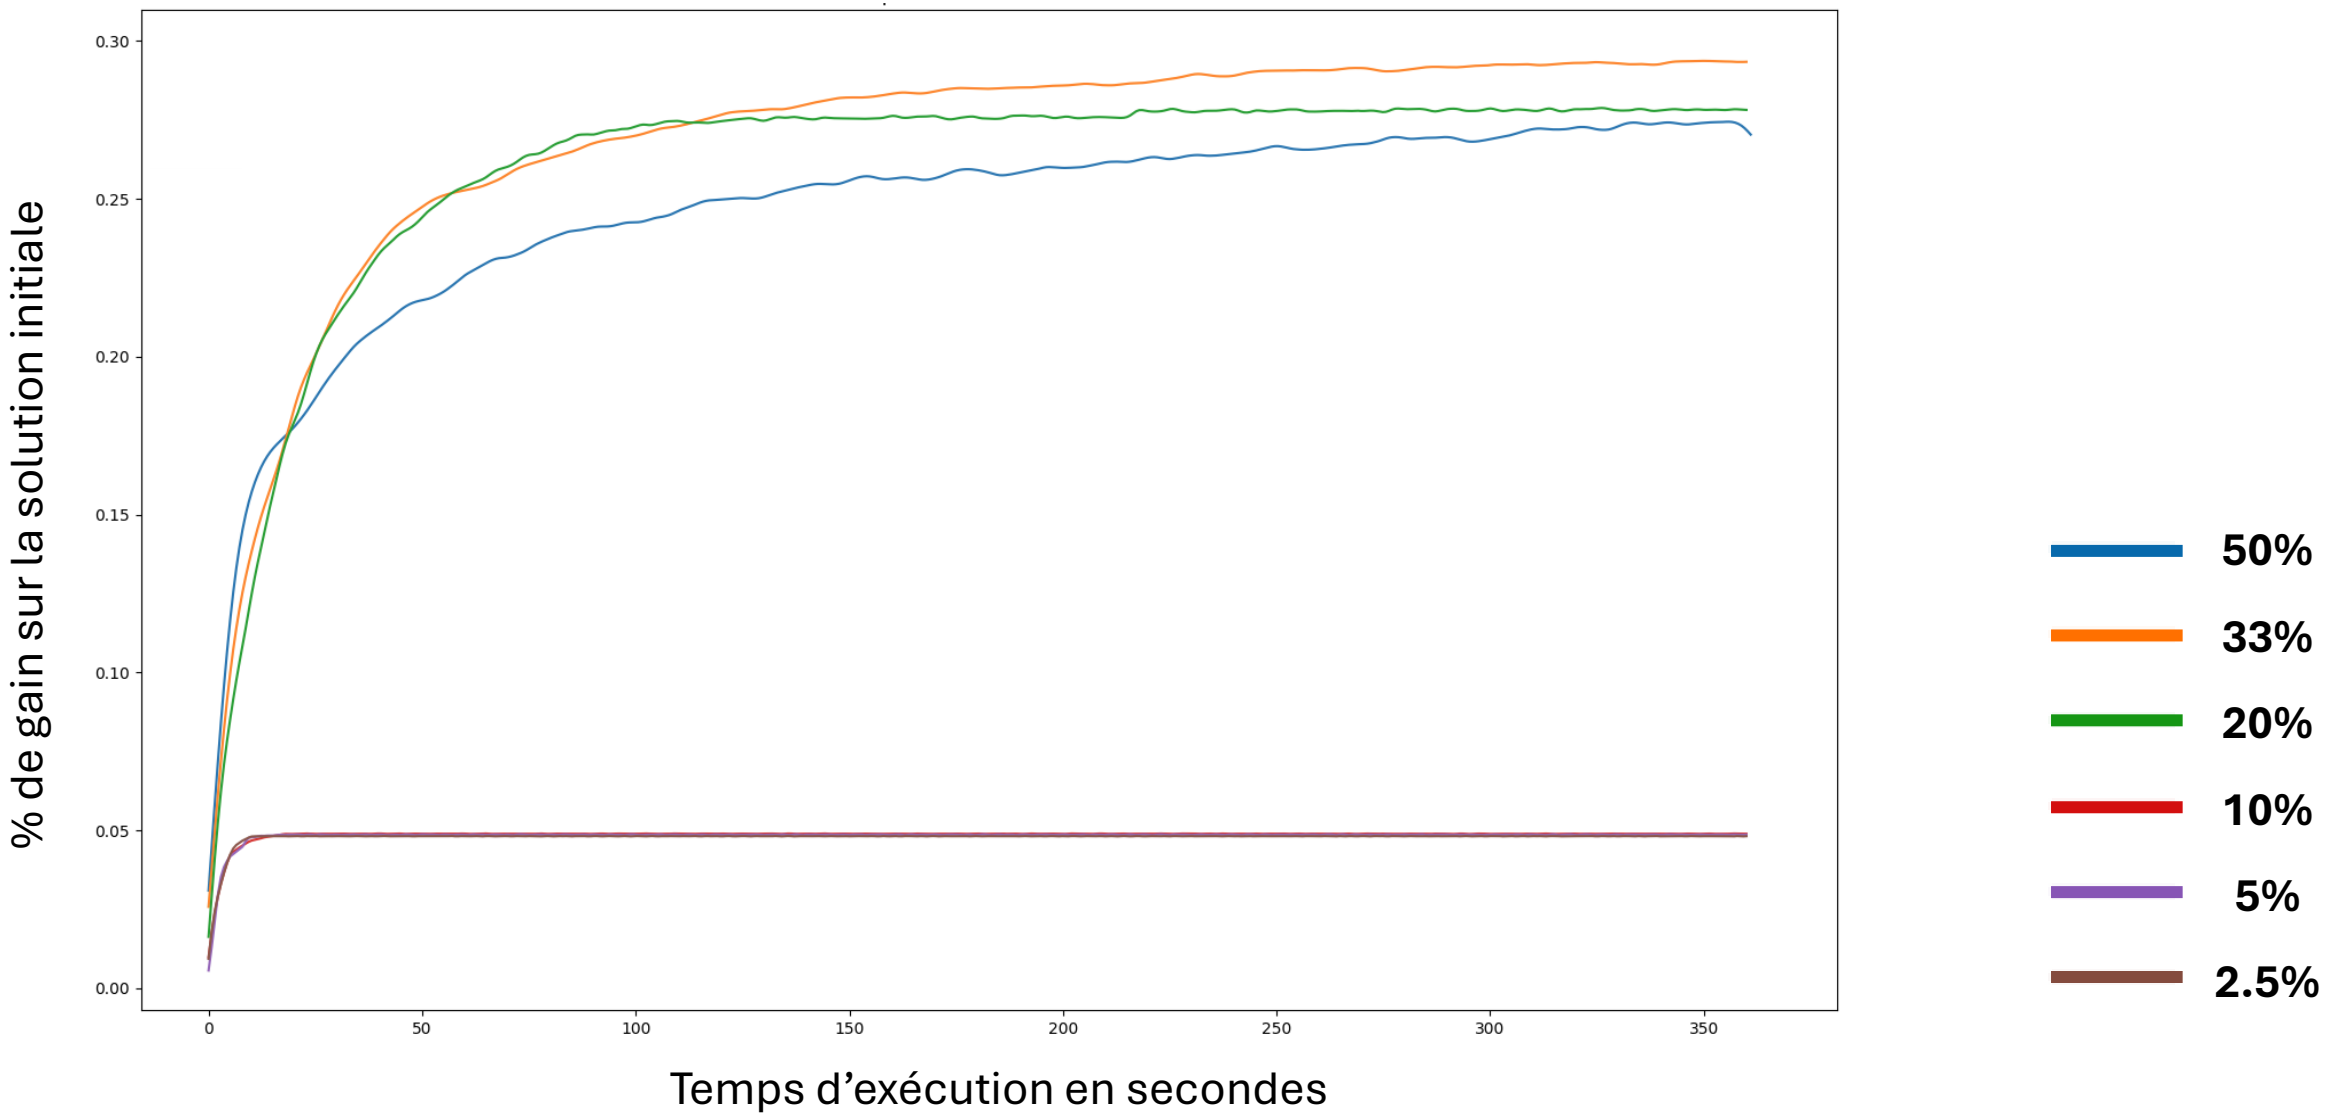
$$O\left(R + C(E + V) + \lambda \cdot C \cdot V + \lambda \cdot C^2\left(V \cdot R + X(V + R)\right)\right)$$

$$\downarrow$$

$$\boldsymbol{O\left(\lambda \cdot C^2\left(V \cdot R + X(V + R)\right)\right)}$$

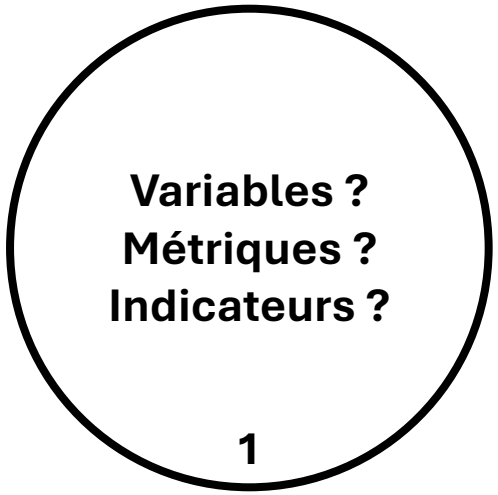
- V : Vidéos
- C : Caches
- E : Endpoints
- X: Capacité des caches
- R : Requêtes
- λ : taux de destruction de cache

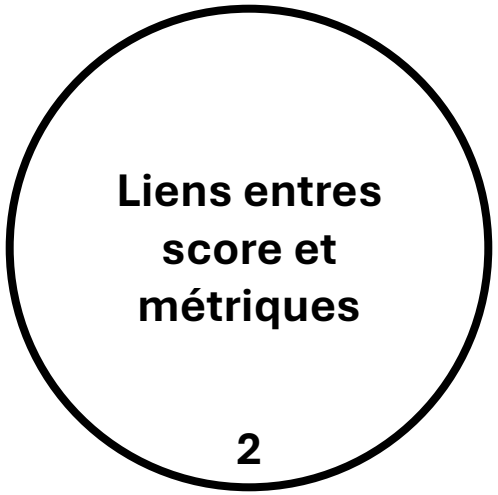
Comparaison de différents λ sur instance2

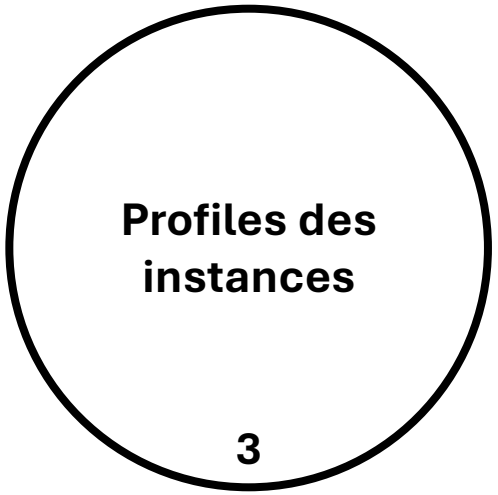


Analyse des Instances

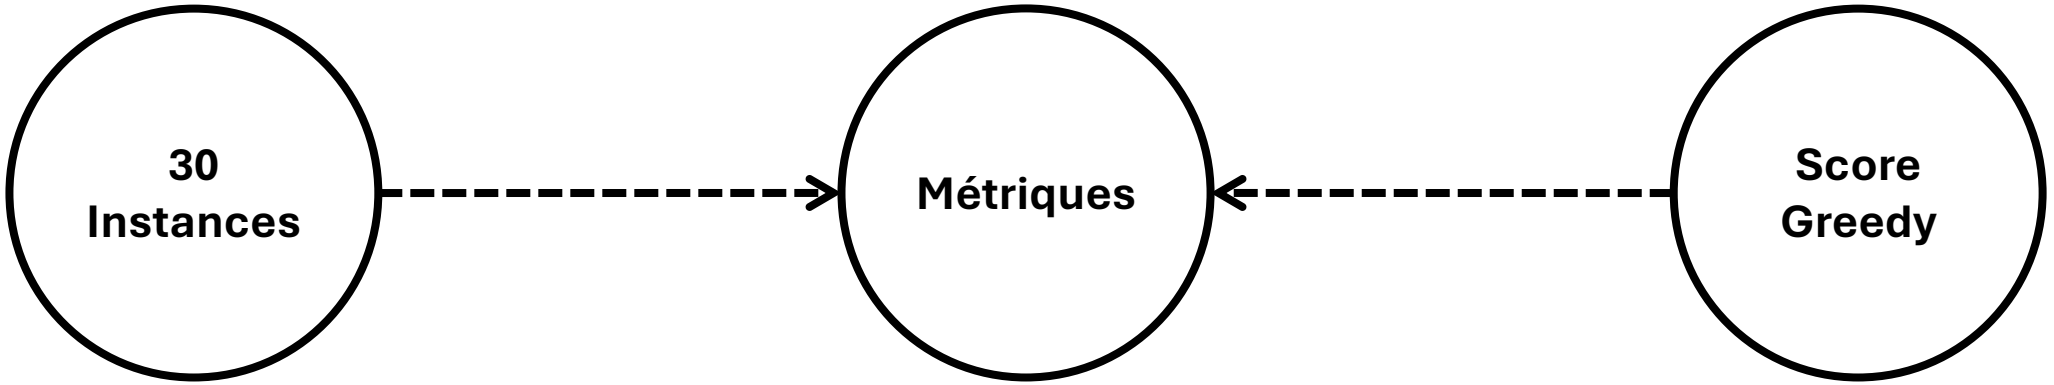
Questions centrales







Présentation de la méthodologie



Publiés avant le 8 octobre

Générateurs : Au moins 3 groupes

Source : Discord

Calcul des métriques

Corrélation de Kendall

ACP

Résultats du 9 octobre au soir

Proportion au Meilleur Score Global

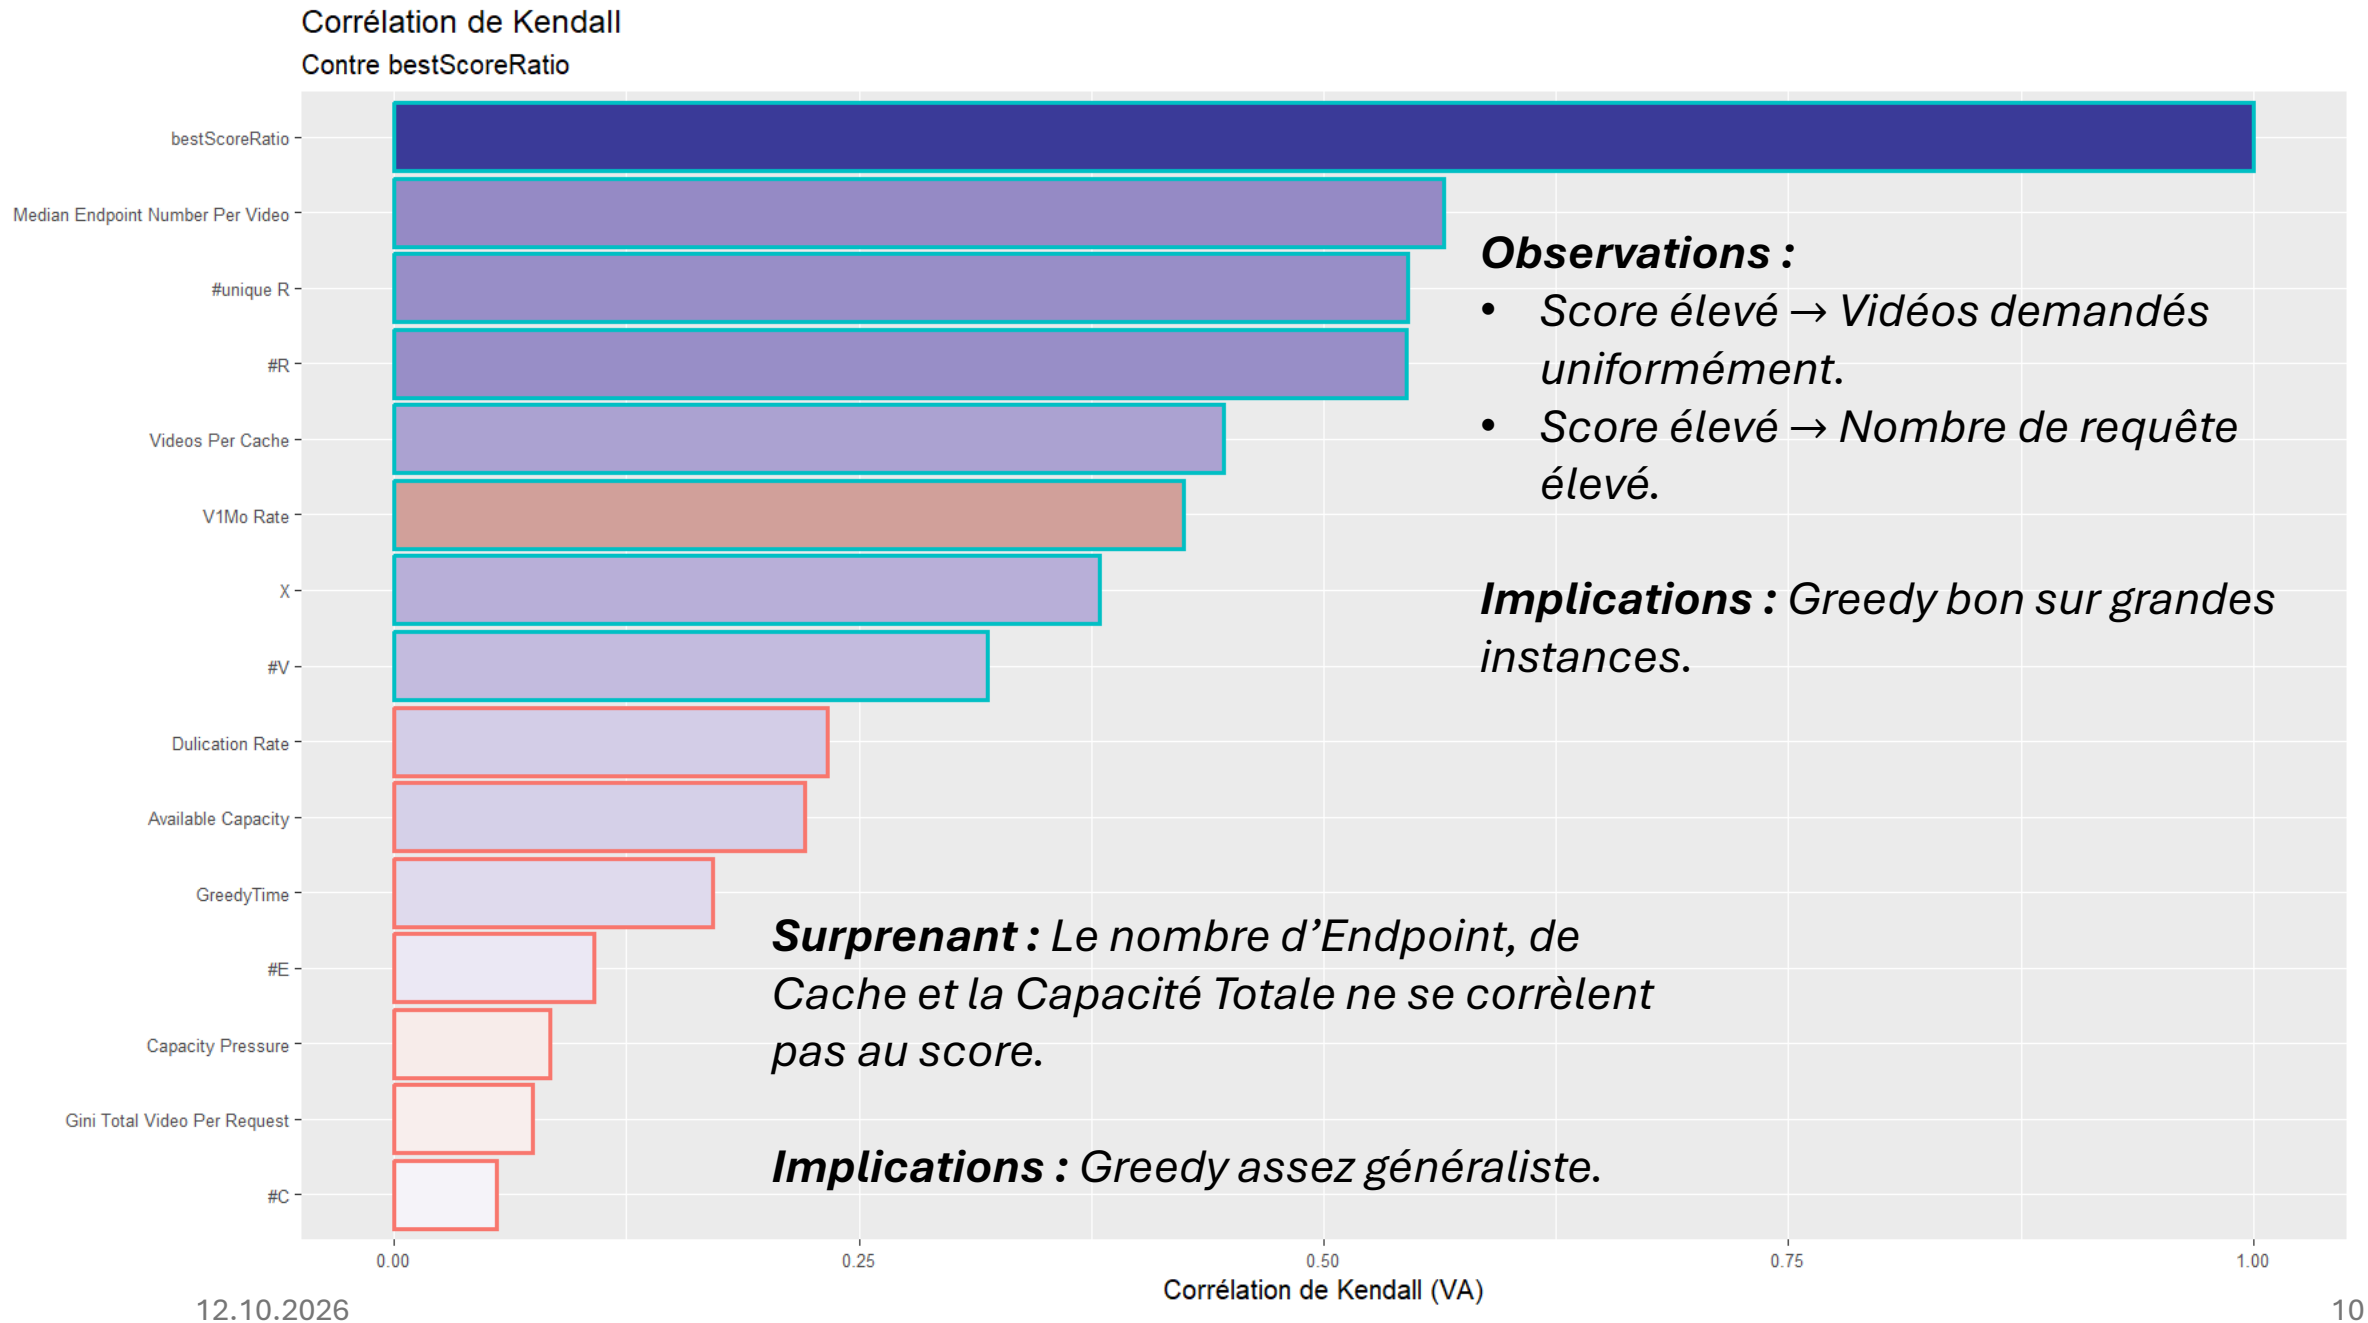
Métriques de base sur les instances

- ***Nombre de vidéo :*** $\#V$
- ***Nombre d'Endpoint :*** $\#E$
- ***Nombre de Requêtes :*** $\#R$
- ***Nombre de Caches :*** $\#C$
- ***Capacité en Cache :*** X

Intéressant : Sur les instances, distributions bimodales, petites valeurs et valeurs maximales, rien au milieu.

Métriques supplémentaires sur les instances

- Taux de duplication (>50% en dessous de 1%)
- Nombre de requêtes « uniques » ($\#R$ après retrait duplication)
- Capacité disponible ($\#C \cdot X$)
- Nombre moyen de vidéo par cache
- Taux de vidéo à 1Mo
- Nombre médian d'Endpoint par vidéo
- Pression sur la capacité $\frac{\#C \cdot X}{\sum_{v \in V} size(v) cacheable(v) isRequested(v)}$



Observations :

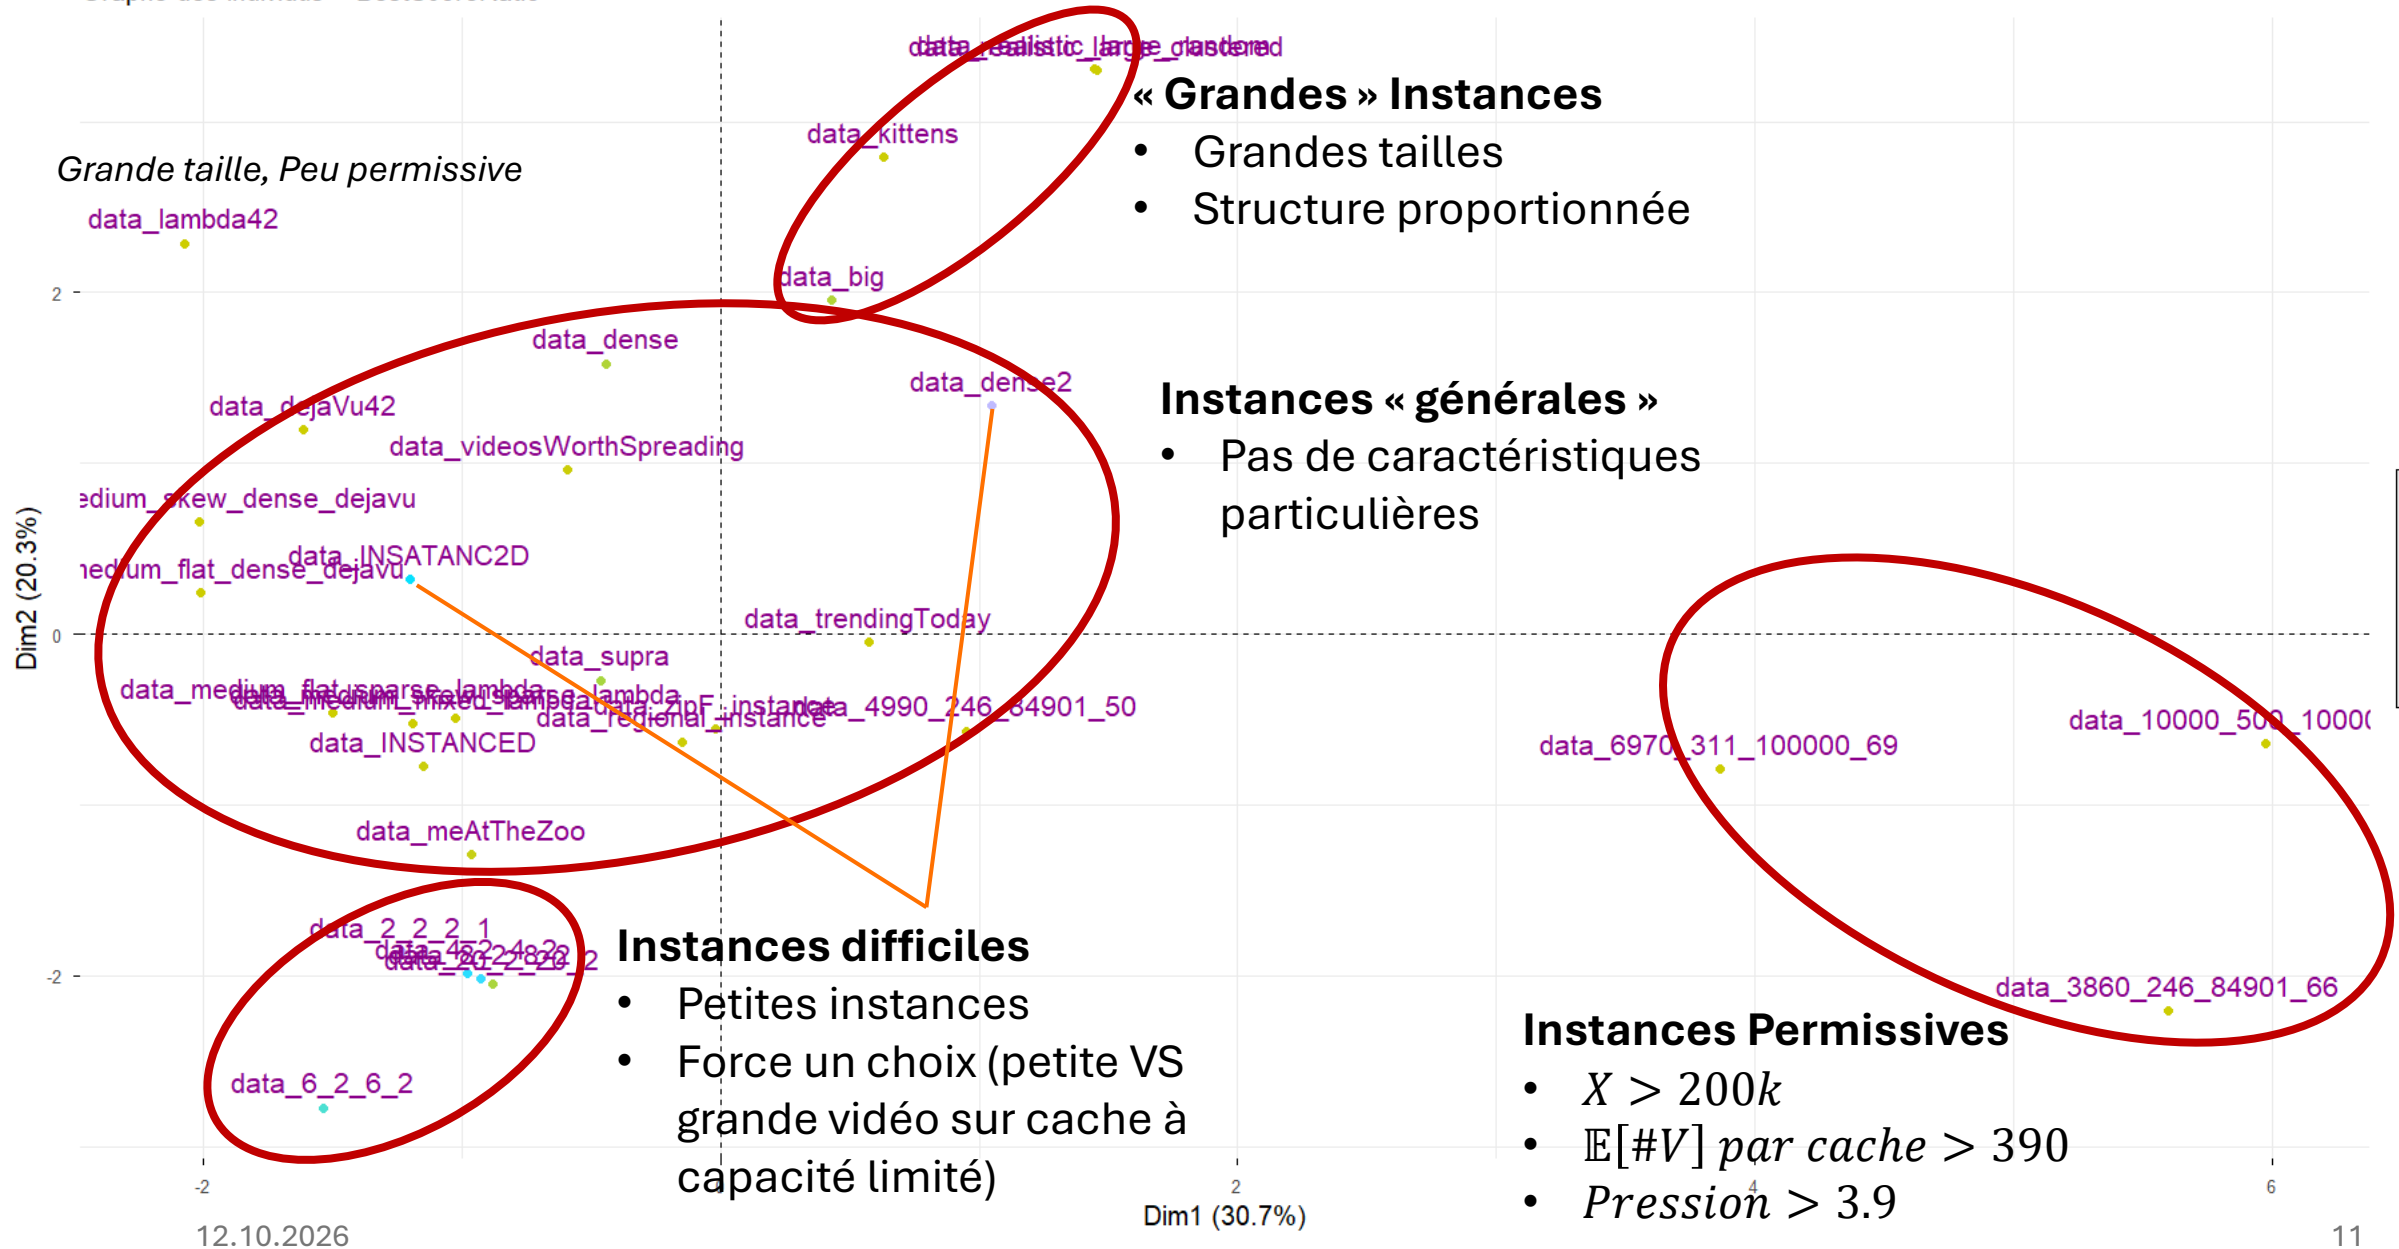
- *Score élevé → Vidéos demandés uniformément.*
- *Score élevé → Nombre de requête élevé.*

Implications : *Greedy bon sur grandes instances.*

Surprenant : *Le nombre d'Endpoint, de Cache et la Capacité Totale ne se corrèlent pas au score.*

Implications : *Greedy assez généraliste.*

Dim1 $(structure) : X, vidéo\ par\ cache$
Dim2 $(taille) : \#V, \#uniqueR, \#C, \#\mathrm{E}$



« Grandes » Instances

- Grandes tailles
- Structure proportionnée

Instances « générales »

- Pas de caractéristiques particulières

Instances difficiles

- Petites instances
- Force un choix (petite VS grande vidéo sur cache à capacité limité)

Instances Permissives

- $X > 200k$
- $\mathbb{E}[\#V]\ par\ cache > 390$
- $Pression > 3.9$

INSTANCES FOURNIES PAR GOOGLE

instance \ score groupe	VBS	A	B	C	D	E	F	G	H	I	J	K
kittens	1024967	1022556	507470	1021696	1022115	967433	964093	858883		537 077	1022967	1024967
me_at_the_zoo	516557	507906	301747	512115	507906	505619	497300	491182		495 952	512115	516557
trending_today	500000	499966	327080	499966	499966	499979	499966	499991		499 980	499966	500000
videos_worth_spreading	614545	611597	24748	610596	609385	605129	603656	560579		532 970	610239	614545
TOTAL	2 656 069	2 642 025	1 161 045	2 644 373	2 639 372	2 578 160	2 565 015	1 551 752	0	2 065 979	2 645 287	2 656 069
Classement Hashcode	3	12	1573	10	18	56	66	1272		528	8	3
Classement Local		4	10	3	5	6	7	9	13	8	2	1

Analyse SWOT

Greedy par densité → Ruin & Recreate

Strengths

- Approche généraliste et performante
- Bons scores vis-à-vis du groupe et du concours officiel
- Ruin & Recreate pour échapper de l'optimum local

Weaknesses

- Choix myope : une petite vidéo peut en bloquer une grande
- Gain marginal avec chaque couche de calcul
- Lent sur les grandes instances

Opportunities

- Avec la classification d'instances, implémenter des algorithmes adaptés pour chaque cluster
- Réoptimisation supplémentaire par Knapsack

Threats

- Instances pièges faciles à construire, à toute échelle
- Overfitting sur les instances officielles